

BÁO CÁO CHUYÊN ĐỀ CUỐI KỲ
MÔN LẬP TRÌNH CHO KHOA HỌC DỮ LIỆU

**PHÂN TÍCH BÁN HÀNG, QUẢN LÝ TỒN KHO
VÀ PHÂN NHÓM KHÁCH HÀNG**

Học viên:

Mã học viên:

Giảng viên:

Hình thức thực hiện: Cá nhân

Phạm vi: Nhà sách và văn phòng phẩm

Tháng 08 năm 2026

LỜI CAM ĐOAN VÀ PHẠM VI SỬ DỤNG AI

Báo cáo này trình bày dự án cá nhân về phân tích bán hàng, quản lý tồn kho và phân nhóm khách hàng. Dữ liệu giao dịch và khách hàng được mô phỏng bằng seed cố định; không chứa thông tin nhận diện khách hàng thật.

AI được sử dụng để gợi ý cấu trúc, rà soát mã, giải thích lỗi, đề xuất kiểm thử và phản biện kết quả. Mọi đầu ra được kiểm tra lại bằng cách chạy pipeline, đối chiếu số dòng, khóa dữ liệu, chỉ số mô hình và biểu đồ. Nhật ký sử dụng AI được lưu tại logs/ai_usage_log.md.

Nguồn trực tuyến chỉ được truy cập ở phạm vi công khai, có timeout và khoảng nghỉ. Dự án không vượt CAPTCHA, đăng nhập, token nội bộ hoặc cơ chế chống bot.

Người thực hiện chịu trách nhiệm giải thích mã nguồn, dữ liệu, giả định, giới hạn và kết quả được trình bày trong báo cáo.

Danh mục tệp minh chứng

- Mã nguồn theo lớp và module trong src/
- Bốn notebook bắt buộc trong notebooks/
- Dữ liệu gốc và dữ liệu sạch trong data/raw và data/processed
- Nhật ký lỗi, crawl và AI trong logs/
- Biểu đồ, metric và phân tích sai số trong reports/

TÓM TẮT

Dự án xây dựng pipeline khoa học dữ liệu hoàn chỉnh cho cửa hàng nhà sách và văn phòng phẩm. Catalog cuối gồm 90 sản phẩm; dữ liệu giao dịch gồm 1,200 đơn, 3,274 dòng chi tiết, 220 khách hàng và 3,396 giao dịch kho.

Hệ thống nghiệp vụ được tổ chức theo hướng đối tượng với các lớp Product, Customer, Order, OrderItem, InventoryTransaction, InventoryManager và SalesManager. Giao dịch làm tồn kho âm bị từ chối; thao tác bán hàng có rollback khi một dòng không đủ hàng.

Phân phân tích sử dụng NumPy, Pandas, Groupby, Pivot và trực quan hóa. Kết quả cho thấy doanh thu chịu ảnh hưởng mạnh bởi nhóm thiết bị văn phòng có đơn giá cao; kênh offline đóng góp lớn nhất và số sản phẩm dưới mức đặt lại tương đối cao.

Bài toán học máy so sánh baseline với Linear/Logistic Regression và Decision Tree. Decision Tree đạt R^2 khoảng 0,79 cho giá trị đơn và F1 khoảng 0,98 cho cảnh báo tồn kho trên dữ liệu mô phỏng. RFM và K-Means tạo bốn phân khúc cùng chiến lược chăm sóc.

Kết quả chỉ minh họa quy trình kỹ thuật, chưa phù hợp để tự động ra quyết định kinh doanh khi chưa kiểm chứng trên dữ liệu thực.

Từ khóa

OOP, quản lý tồn kho, bán hàng, NumPy, Pandas, EDA, hồi quy, phân lớp, RFM, K-Means.

MỤC LỤC VÀ CẤU TRÚC BÁO CÁO

1. Giới thiệu và câu hỏi nghiên cứu
2. Phạm vi, đạo đức và nguồn dữ liệu
3. Thiết kế dữ liệu và kiến trúc pipeline
4. OOP và nghiệp vụ kho
5. Thu thập, làm sạch và kiểm tra chất lượng
6. NumPy, dictionary lồng nhau, Merge/Groupby/Pivot
7. EDA bán hàng, tồn kho và khách hàng
8. Học máy dự đoán giá trị đơn
9. Học máy cảnh báo tồn kho
10. RFM, K-Means và chiến lược
11. Giới hạn, tái lập và kết luận

Phụ lục: cấu trúc tệp, cách chạy và câu hỏi bảo vệ.

Lưu ý: cập nhật trường họ tên, mã học viên và giảng viên trên trang bìa trước khi nộp.

1. GIỚI THIỆU VÀ CÂU HỎI NGHIÊN CỨU

Cửa hàng cần theo dõi nhập, xuất, điều chỉnh tồn kho, doanh thu và hành vi khách hàng trong một quy trình thống nhất. Nếu chỉ lưu bảng giao dịch mà thiếu kiểm soát nghiệp vụ, tồn kho có thể âm hoặc số liệu báo cáo không nhất quán. Nếu chỉ xây dựng chương trình nghiệp vụ mà không phân tích dữ liệu, hệ thống khó hỗ trợ quyết định.

Mục tiêu của chuyên đề là kết hợp lập trình Python hướng đối tượng với quy trình khoa học dữ liệu: thiết kế dữ liệu, thu thập, kiểm tra chất lượng, làm sạch, phân tích khám phá, học máy, phân cụm và báo cáo có thể tái lập.

1. Danh mục và kênh bán nào tạo doanh thu lớn nhất?
2. Sản phẩm nào bán chạy, bán chậm và thường được mua cùng nhau?
3. Thời điểm nào có doanh thu cao nhất?
4. Khách hàng có thể chia thành những nhóm RFM nào?
5. Có thể dự đoán giá trị đơn hàng với sai số bao nhiêu?
6. Sản phẩm nào có nguy cơ xuống dưới mức cảnh báo?

2. PHẠM VI, ĐẠO ĐỨC VÀ NGUỒN DỮ LIỆU

Nguồn	Số SP	Vai trò	source_type
Giảng viên	60	Dữ liệu sản phẩm khởi đầu	lecturer
DummyJSON	15	API sản phẩm công khai	public_api
Books to Scrape	15	Website thực hành công khai	public_website
HTML mẫu	60	Đối chiếu parser, không tính SP mới	practice

Dữ liệu sản phẩm công khai được bổ sung ở phạm vi nhỏ, có metadata URL và thời điểm thu thập. Giá USD được nhân 25.000 và giá GBP được nhân 33.000 để quy đổi sang VND. Tỷ giá cố định là giá định học tập, không phải tỷ giá giao dịch.

Các trường product_id mới, popularity_weight, paired_product_id và một phần tồn kho được mô phỏng; cột simulated_fields ghi rõ theo từng bản ghi. Customers, orders, order_details và inventory_transactions là dữ liệu synthetic với seed=42.

Không có tên, điện thoại, email hoặc địa chỉ chi tiết của khách hàng thật.

3. THIẾT KẾ DỮ LIỆU

Bảng	Số dòng	Khóa	Nội dung
products	90	product_id	Danh mục, giá, tồn đầu, reorder
customers	220	customer_id	Thành phố, loại KH, ngày tham gia
orders	1200	order_id	Ngày, thanh toán, kênh, giảm giá
order_details	3274	order_id + product_id	Số lượng, giá bán
inventory_transactions	3396	transaction_id	Loại giao dịch, trạng thái

Quan hệ chính: customers 1–n orders; orders 1–n order_details; products 1–n order_details; products 1–n inventory_transactions. Khi tạo fact_sales, các phép merge dùng validate='many_to_one' để chặn cardinality ngoài dự kiến.

Bảng fact_sales giữ cấp độ dòng chi tiết đơn, bổ sung thuộc tính khách hàng, sản phẩm, tháng, doanh thu dòng, phần giảm giá phân bổ và doanh thu ròng.

4. KIẾN TRÚC PIPELINE VÀ KHẢ NĂNG TÁI LẬP

Pipeline được chia thành module theo nhiệm vụ thay vì đặt toàn bộ mã trong notebook. Các script buổi 4–8 lần lượt làm sạch/sinh dữ liệu, merge/tổng hợp, EDA, học máy và RFM. `run_all.py` điều phối toàn bộ và dừng ngay nếu một bước lỗi.

Chế độ mặc định dùng dữ liệu raw đã lưu để tránh phụ thuộc mạng. Tùy chọn `--with-crawl` kích hoạt lại bước thu thập. Việc tách raw và processed cho phép truy vết thay đổi và không sửa trực tiếp dữ liệu nguồn.

Các tham số ngẫu nhiên quan trọng đều cố định ở 42; ngày tham chiếu RFM cố định là 2026-01-01. Metric, case sai, bảng tổng hợp và hình được ghi thành tệp độc lập.

`python src/run_all.py`

`python src/run_all.py --with-crawl`

`python -m streamlit run src/app_dashboard.py`

5. OOP VÀ NGHIỆP VỤ KHO

Lớp	Trách nhiệm
Product	Thông tin và số lượng hiện tại
Customer	Thông tin khách hàng ẩn danh
OrderItem	Một dòng sản phẩm trong đơn
Order	Header đơn và danh sách dòng
InventoryTransaction	Trạng thái trước/sau giao dịch
InventoryManager	Nhập/xuất/điều chỉnh, log và kiểm tra
SalesManager	Tạo đơn, trừ kho và rollback

InventoryManager là nguồn sự thật cho số lượng hiện tại. Mọi thao tác được kiểm tra đầu vào, ghi quantity_before, quantity_after, người thực hiện, trạng thái và ghi chú.

Khi xuất vượt tồn, hệ thống tạo giao dịch rejected và ghi error_log thay vì làm tồn kho âm. Khi tạo đơn nhiều dòng, nếu một dòng thất bại thì các dòng đã trừ trước đó được hoàn tác.

6. THU THẬP VÀ KIỂM TRA CHẤT LƯỢNG

Bước thu thập có timeout, kiểm tra HTTP status, khoảng nghỉ và xử lý lỗi theo nguồn. HTML mẫu hai trang được parse bằng selector cụ thể rồi đối chiếu 60/60 sản phẩm với dữ liệu giảng viên.

Dữ liệu DummyJSON và Books to Scrape được ánh xạ về schema chung. Metadata source_type, source_reference, source_url và collected_at được giữ lại. Nhật ký crawl mô tả số lượng và lỗi.

Các kiểm tra chất lượng bao gồm số ô thiếu, trùng product_id, giá không dương, initial_quantity không lớn hơn reorder_level, kiểu dữ liệu và tính hợp lệ của paired_product_id.

source_type	products	avg_price	categories
lecturer_sample	60	207,633.33	6
public_api	15	17,216,416.67	2
public_website	15	1,200,650.00	1

7. LÀM SẠCH, HỢP NHẤT VÀ KIỂM TRA KHÓA

Chuỗi xử lý chuẩn hóa khoảng trắng, kiểu số, đơn vị, danh mục và thông tin nguồn; loại khóa trùng; sửa reorder_level không hợp lệ theo quy tắc công bố. Khi trùng product_id, bản ghi giảm viên được ưu tiên.

Sau merge, catalog có 90 khóa product_id duy nhất, unit_price dương và initial_quantity lớn hơn reorder_level. Khóa ngoại từ order_details và inventory_transactions sang products được kiểm tra.

Fact table có 3,274 dòng, bằng số dòng order_details. Các bước merge không làm tăng số dòng bất thường.

Kiểm tra	Kết quả
products.product_id duy nhất	True
orders.order_id duy nhất	True
order_details FK order hợp lệ	True
order_details FK product hợp lệ	True
inventory FK product hợp lệ	True

8. DICTIONARY LỒNG NHAU VÀ NUMPY

Một mẫu giao dịch được biểu diễn theo cấu trúc order → customer/order/items. Vòng lặp trên dictionary lồng nhau tính doanh thu đơn, chi tiêu khách hàng và tần suất cập sản phẩm mà không phụ thuộc Groupby.

Mẫu gồm 41 đơn với doanh thu 1,123,899,409 VND. Kết quả chi tiết được ghi JSON để kiểm tra.

Ma trận NumPy doanh thu tháng × danh mục có kích thước (12, 7). `sum(axis=1)` tính tổng theo tháng; `sum(axis=0)` tính tổng theo danh mục. Z-score được tính theo cột và trung bình sau chuẩn hóa xấp xỉ 0.

Giá trị tồn kho đầu kỳ được vector hóa bằng phép nhân hai mảng, đạt 15,230,705,000 VND.

year_month	Bút viết	Dụng cụ học tập	Hồ sơ và lưu trữ	Phụ kiện máy tính	Sách	Thiết bị văn phòng	Vở và giấy
2025-01	3,619,120.24	2,754,845.96	10,886,806.70	286,894,020.27	383,523,356.23	905,252,371.38	9,791,846.22
2025-02	5,981,272.60	5,844,098.33	11,939,555.70	114,975,505.94	299,251,484.41	2,082,989,294.55	13,601,459.45
2025-03	7,086,279.57	2,862,488.12	6,921,788.55	389,163,602.74	364,842,753.81	3,547,702,001.11	9,280,180.10
2025-04	5,264,831.37	7,394,010.50	5,559,720.30	175,927,503.49	425,675,491.21	6,130,893,422.37	11,123,913.76
2025-05	6,437,593.91	8,924,342.19	5,779,054.84	268,271,769.82	598,699,722.74	2,724,105,080.33	12,245,169.17
2025-06	2,222,697.22	3,960,081.22	5,289,886.73	238,547,329.45	368,300,656.90	2,902,624,600.65	7,032,991.83
2025-07	7,090,953.90	5,952,947.25	9,535,556.49	456,406,124.38	513,998,024.65	2,112,911,383.17	18,775,964.15
2025-08	3,597,561.11	3,032,548.38	6,491,880.02	204,408,920.49	289,829,022.89	2,850,764,499.98	9,437,567.13

9. MERGE, GROUPBY VÀ PIVOT


Các bảng tổng hợp gồm doanh thu theo tháng, danh mục, thành phố, kênh, phương thức thanh toán, top sản phẩm và tồn kho. Pivot tháng $\times$ kênh hỗ trợ so sánh cơ cấu theo thời gian; pivot danh mục $\times$ thanh toán hỗ trợ phân tích hành vi.

Doanh thu dòng bằng $\text{quantity} \times \text{selling_price}$. Discount cấp đơn được phân bổ theo tỷ trọng doanh thu dòng để tránh tính lặp khi tổng hợp.

Tồn kho hiện tại được tính theo thứ tự timestamp và transaction_id, với dấu dương cho nhập, dấu âm cho bán/xuất/hao hụt điều chỉnh.

year_month	orders	quantity	gross_revenue	net_revenue
2025-01	88	1211	1,603,057,367.00	1,602,722,367.00
2025-02	92	1561	2,535,082,671.00	2,534,582,671.00
2025-03	86	1467	4,327,979,094.00	4,327,859,094.00
2025-04	103	1731	6,762,348,893.00	6,761,838,893.00
2025-05	103	2095	3,624,867,733.00	3,624,462,733.00
2025-06	95	1330	3,528,278,244.00	3,527,978,244.00
2025-07	110	1876	3,125,135,954.00	3,124,670,954.00
2025-08	96	1211	3,368,017,000.00	3,367,562,000.00
2025-09	112	1668	3,134,178,123.00	3,133,658,123.00
2025-10	110	1812	3,346,218,263.00	3,345,908,263.00
2025-11	93	1771	2,533,101,075.00	2,532,726,075.00
2025-12	112	2034	5,016,231,466.00	5,015,691,466.00

10. EDA — DOANH THU THEO THỜI GIAN




Hình 1. Doanh thu ròng theo tháng


Doanh thu biến động theo tháng và đạt đỉnh vào 2025-04. Mức biến động phản ánh đồng thời số đơn, số lượng và cơ cấu mặt hàng có giá cao.

Do dữ liệu giao dịch là synthetic, không nên diễn giải đỉnh tháng như quan hệ nhân quả hoặc mùa vụ thật. Kết quả phù hợp để kiểm tra kỹ thuật tổng hợp theo thời gian.

11. EDA — DANH MỤC VÀ SẢN PHẨM



Hình 2. Doanh thu theo danh mục




Hình 3. Sản phẩm bán chạy và bán chậm


Thiết bị văn phòng dẫn đầu doanh thu vì catalog bổ sung có laptop/tablet đơn giá cao. Kết quả bị chi phối bởi cơ cấu nguồn và tỷ giá cố định.

Sản phẩm bán chạy được đo theo tổng số lượng; sản phẩm doanh thu cao được đo theo net_revenue. Hai tiêu chí có thể cho thứ hạng khác nhau.

12. EDA — KÊNH BÁN VÀ THÀNH PHỐ



Hình 4. Cơ cấu doanh thu theo kênh




Hình 5. Doanh thu theo thành phố

Kênh offline chiếm khoảng 42% doanh thu và TP. Hồ Chí Minh dẫn đầu trong dữ liệu mô phỏng. Các phân bố được sinh theo quy tắc có kiểm soát, không đại diện thị phần thật.

13. EDA — GIÁ TRỊ ĐƠN VÀ CẶP SẢN PHẨM



Hình 6. Phân bố giá trị đơn hàng




Hình 7. Ma trận đồng mua sản phẩm


Giá trị đơn lệch phải và có các ngoại lệ lớn do thiết bị giá cao. Điều này giải thích vì sao MAE, RMSE và R^2 cần được xem đồng thời.

Cặp mua cùng được tạo từ các sản phẩm duy nhất trong cùng đơn; ma trận đối xứng và đường chéo bị đặt bằng 0.

14. EDA — TỒN KHO VÀ RFM THÔ



Hình 8. Tồn kho hiện tại so với reorder level



Hình 9. Phân bố RFM thô

Có 77/90 sản phẩm bằng hoặc dưới reorder_level trong kịch bản mô phỏng. Tỷ lệ cao tạo bài toán phân lớp mất cân bằng và không phản ánh tỷ lệ thực tế của cửa hàng.

Recency, Frequency và Monetary có thang đo khác nhau; Monetary lệch phải nên được log1p trước chuẩn hóa và phân cụm.

15. HỌC MÁY — DỰ ĐOÁN GIÁ TRỊ ĐƠN

Model	MAE	RMSE	R2
DummyRegressor	43,986,056.88	82,558,035.54	-0.01
LinearRegression	33,258,995.85	73,418,632.27	0.20
DecisionTreeRegressor	10,756,912.79	37,851,808.60	0.79

Dữ liệu được chia train/test trước khi fit. ColumnTransformer xử lý biến số và biến phân loại trong Pipeline. Baseline DummyRegressor dùng trung bình làm mốc.

DecisionTreeRegressor cho MAE khoảng 10,8 triệu VND và R^2 khoảng 0,79, tốt hơn rõ rệt so với baseline và Linear Regression. Tuy nhiên độ chính xác phụ thuộc mạnh vào quy tắc sinh dữ liệu và sản phẩm giá cao.

Mười trường hợp sai lớn nhất được lưu riêng; phần lớn liên quan đơn có avg_selling_price cao hoặc cấu trúc số lượng hiếm.

16. HỌC MÁY — CẢNH BÁO TỒN KHO


Model	Accuracy	Precision	Recall	F1
DummyClassifier	0.85	0.85	1.00	0.92
LogisticRegression	0.93	1.00	0.91	0.95
DecisionTreeClassifier	0.96	1.00	0.96	0.98

Nhấn `low_stock` bằng 1 khi `current_quantity` $\leq$ `reorder_level`. Đặc trưng chỉ dùng thông tin đầu kỳ và bán/nhập nửa đầu năm để hạn chế rò rỉ từ kết quả cuối kỳ.


DecisionTreeClassifier đạt F1 khoảng 0,98; Logistic Regression cũng vượt baseline. Vì lớp dương chiếm khoảng 85%, Accuracy không đủ để đánh giá và phải xem Precision, Recall, F1.

Tập chỉ có 90 sản phẩm nên kết quả có phương sai cao. Mô hình không nên tự động đặt hàng nếu chưa có dữ liệu lịch sử thực và kiểm thử theo thời gian.

17. RFM VÀ K-MEANS



Hình 10. Các cụm khách hàng RFM



Hình 11. Quy mô phân khúc

Ngày tham chiếu cố định 2026-01-01. Recency tính số ngày từ lần mua gần nhất; Frequency là số đơn duy nhất; Monetary là tổng doanh thu ròng.

Dữ liệu dùng recency_days, frequency và $\log_{10}(\text{monetary})$, sau đó StandardScaler. Số cụm được lựa chọn bằng silhouette trong khoảng $k=3-6$; $k=4$ cho kết quả tốt nhất trong lần chạy hiện tại.

18. CHIẾN LƯỢC THEO PHÂN KHÚC

segment	customers	recency_mean	frequency_mean	monetary_mean
At Risk	17	76.12	2.71	3,234,645.12
Champions	78	30.06	7.67	411,842,769.95
Loyal	88	41.26	4.68	73,913,912.78
Potential	36	161.42	4.00	117,125,320.42

Champions: Ưu đãi VIP, early access, chăm sóc cá nhân hóa và giữ chân.

Loyal: Tích điểm, upsell/cross-sell và gợi ý sản phẩm mua cùng.

Potential: Coupon kích hoạt đơn tiếp theo và nội dung theo danh mục quan tâm.

At Risk: Chiến dịch win-back có thời hạn, khảo sát lý do và giới hạn chi phí.

Tên phân khúc được gán sau khi xem trung bình cụm, không phải nhãn thật. Khi triển khai cần theo dõi tỷ lệ phản hồi, chi phí và quyền riêng tư.

19. GIỚI HẠN, RỦI RO VÀ HƯỚNG PHÁT TRIỂN

- Giao dịch và khách hàng là synthetic nên không phản ánh hành vi thực.
- FX cố định và thiết bị giá cao làm doanh thu lệch mạnh.
- Tập tồn kho chỉ có 90 sản phẩm và mất cân bằng lớp.
- Chia train/test ngẫu nhiên phù hợp minh họa nhưng chưa phải đánh giá theo thời gian.
- RFM phụ thuộc ngày tham chiếu và quy tắc gán tên cụm.
- Nguồn web có thể thay đổi cấu trúc hoặc ngừng truy cập.

Hướng phát triển

- Thu thập lịch sử bán hàng thật đã ẩn danh và thiết kế đánh giá theo thời gian.
- Dự báo nhu cầu theo sản phẩm, thời gian giao hàng và chi phí thiếu hàng.
- Hiệu chỉnh ngưỡng reorder theo service level thay vì nhãn cố định.
- Theo dõi drift mô hình và hiệu quả chiến dịch theo phân khúc.
- Bổ sung kiểm thử tự động, data validation và version hóa dữ liệu.

20. KẾT LUẬN

Dự án đáp ứng chuỗi yêu cầu của Chuyên đề 6: OOP quản lý kho, File I/O, dictionary lồng nhau, NumPy, Pandas, Merge/Groupby/Pivot, EDA, mô hình giám sát, phân tích sai số và RFM/K-Means.

Quy mô dữ liệu vượt mức tối thiểu: 90 sản phẩm, 220 khách hàng, 1,200 đơn và 3,274 dòng chi tiết. Pipeline tạo lại các bảng, biểu đồ, metric và phân khúc bằng một lệnh.

Kết quả học máy cho thấy Decision Tree phù hợp hơn baseline trong dữ liệu mô phỏng, nhưng không chứng minh khả năng vận hành trên dữ liệu thật. Giá trị chính của dự án là quy trình có kiểm soát, minh bạch về nguồn và giả định.

Lệnh chạy

```
python src/run_all.py
```

```
python -m streamlit run src/app_dashboard.py
```

PHỤ LỤC A — CẤU TRÚC SẢN PHẨM NỘP

- notebooks/01_problem_and_data.ipynb
- notebooks/02_collection_and_cleaning.ipynb
- notebooks/03_eda.ipynb
- notebooks/04_machine_learning.ipynb
- src/models.py, inventory_manager.py, sales_manager.py
- src/crawl_*.py, clean_products.py, merge_products.py, validate_products.py
- src/run_buoi4.py ... run_buoi8_rfm.py, run_numpy_evidence.py, run_all.py
- data/raw/, data/processed/, logs/, reports/figures/
- reports/BAO_CAO_CHUYEN_DE_6.docx
- reports/SLIDE_CHUYEN_DE_6.pptx

Kiểm tra trước khi nộp

7. Điền họ tên, mã học viên và tên giảng viên.
8. Mở Word, cập nhật mục lục nếu cần và kiểm tra ngắt trang.
9. Kiểm tra font, hình, số liệu và các liên kết tệp.
10. Chạy pipeline một lần cuối và lưu log.

PHỤ LỤC B — CÂU HỎI BẢO VỆ GỢI Ý

Hỏi: Vì sao cần validate cardinality khi merge?

Đáp: Để phát hiện khóa trùng gây phình dòng và làm sai doanh thu.

Hỏi: Vì sao RMSE lớn hơn MAE?

Đáp: RMSE phạt mạnh các sai số lớn; dữ liệu có outlier thiết bị giá cao.

Hỏi: Vì sao không chỉ dùng Accuracy?

Đáp: Lớp low_stock mất cân bằng, cần xem Precision, Recall và F1.

Hỏi: Làm sao tránh rò rỉ tồn kho?

Đáp: Chỉ dùng đặc trưng có trước thời điểm dự báo, không dùng lượng bán cả kỳ.

Hỏi: Vì sao log Monetary?

Đáp: Monetary lệch phải; log1p giảm ảnh hưởng khách chi tiêu cực lớn.

Hỏi: Vì sao cố định reference_date?

Đáp: Để RFM tái lập và không đổi theo ngày chạy.

Hỏi: Điểm yếu lớn nhất?

Đáp: Dữ liệu synthetic và quy mô tồn kho nhỏ, chưa chứng minh hiệu quả thực tế.